

$$\epsilon_n = \phi(x_n)w + \eta_n$$

datos i.i.d,  $\Phi = \begin{bmatrix} \phi(x_1) \\ \phi(x_2) \\ \vdots \\ \phi(x_N) \end{bmatrix}$

Minimos Cuadrados

Problema

$$\arg \min_w \|\epsilon - \Phi w\|_2^2$$

Solucion

$$\hat{w} = (\Phi^T \Phi)^{-1} \Phi^T \epsilon$$

Discucion:

Modelo Frecuentista, no asume ningun prior ni tiene incertidumbre, unica solucion que mejor se ajuste a los datos

Minimos Cuadrados Regularizados:

Problema

$$\arg \min_w \|\epsilon - \Phi w\|_2^2 + \lambda \|w\|_2^2$$

Solucion

$$\hat{w} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T \epsilon$$

Discucion:

Iguales que minimos Cuadrados, se añade un termino de regularizacion que permite optimizar para el  $w$  mas simple. Tambien se encarga de que la matriz de valores singulares de la descomposicion SVD no diverga

Maxima Verosimilitud:

Problema

$$\arg \max_w \left[ -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma_n^2) - \frac{1}{2\sigma_n^2} \sum_{n=1}^N \|\epsilon_n - \phi(x_n)w\|_2^2 \right]$$

Solucion

$$\hat{w} = (\Phi^T \Phi)^{-1} \Phi^T \epsilon$$

~~Maximizar~~



$$\arg \min_w \|E - \Phi W\|_2^2$$

## Discusión (ML)

Que la solución sea igual a mínimos cuadrados es un caso especial. Máxima verosimilitud busca una distribución en el espacio  $\mathbb{R}^Q$  de  $\Phi$  que maximice la probabilidad de obtener los datos originales. Sigue siendo un modelo frecuentista.

## Máximo a-posteriori

### Problema

$$\arg \min_w \left[ \frac{1}{2\sigma^2} \sum_{n=1}^N (t_n - \phi(x_n)w)^2 + \frac{1}{2\sigma_w^2} \|w\|_2^2 \right]$$

### Solución

$$\hat{w} = (\Phi^T \Phi + \frac{\sigma_n^2}{\sigma_w^2} \mathbf{I})^{-1} \Phi^T t$$

### Discusión

Máximo a-posteriori es un modelo bayesiano en este caso que la solución sea igual a mínimos cuadrados regularizados es un caso especial de asumir un prior gaussiano.

MAP no es tan vulnerable al sobreajuste como Max Verosimilitud dado el término de regularización.



## Lineal gaussiano

Problem:

$$p(\epsilon^* | \mathcal{E}, \Phi, W) = \int p(\epsilon^* | W) p(W | \mathcal{E}) dW$$

Solution:

$$p(\epsilon^* | \mathcal{E}, W) = \mathcal{N}(\epsilon_* | \Phi^T(x_*) M_W, \beta^{-1} + \Phi^T(x_*) S_W \Phi(x_*))$$

Discussion:

El modelo lineal gaussiano deja de asumir que el prior  $p(W)$  viene de una única distribución y ~~se~~ asigna cada parámetro como una variable aleatoria propia. Sobre todo el prior se aplica una gaussiana multivariada. El resultado de este modelo es una "region" de estimación, en contraste a los valores puntuales de los anteriores modelos.